

EvoRS-Comm: 面向遥感视觉理解的自然演化多智能体框架

——层次化多模态通信与结构化多智能体强化学习

Anonymous Authors

摘要

现有遥感视觉语言多智能体系统大多沿用通用 Agent 的文本通信范式：每个 Agent 将局部视觉理解压缩为自然语言，再由其他 Agent 基于文本继续推理。该过程虽然易于实现，但会丢失空间层次、精确位置与细粒度视觉证据；与此同时，现有多智能体强化学习通常将 Agent 输出视为同质文本 action，难以对遥感任务中的结构化空间消息与连续视觉表征进行联合优化。本文提出 EvoRS-COMM，一个面向遥感视觉理解的自然演化多智能体框架。其宏观目标是让 Agent 的职责、通信对象与通信载荷在任务训练中自适应形成，而不是完全依赖人工固定工作流。具体而言，我们提出层次化多模态通信协议，将遥感场景显式组织为 Scene-Region-Group-Object 四级共享树，并允许 Agent 同时交换文本消息、结构化节点/子树和图像 latent representation。进一步地，我们在 cooperative MARL 基础上提出结构化通信优化目标，将“给谁发、发哪个空间层级、使用何种模态、携带哪些节点/latent”纳入联合策略，并显式建模通信成本、结构一致性与消息冗余。本文给出完整的问题形式化、算法框架和实验协议；由于实验尚未执行，所有数值结果均以 **TBD** 标记，本文不预设任何性能提升。

1 引言

遥感图像与普通自然图像的一个重要差异在于其空间组织方式。遥感影像通常覆盖大范围地表区域，包含大量小目标、功能区域与重复结构。近年来的 VRSBench、XLRS-Bench、CHOICE 与 GEOBench-VLM 等 benchmark 已将遥感理解从单一分类扩展到 VQA、grounding、目标计数、空间关系、超高分辨率理解与时序分析等任务 [1, 2, 3, 4]。然而，现有多 Agent 视觉推理仍主要通过自然语言串联：一个 Agent 观察图像后输出文本，另一个 Agent 再从文本恢复语义与空间线索。

这种通信方式存在两个问题。第一，文本会将原本二维、层次化的视觉证据序列化。例如“图中存在五架飞机”并不能直接告诉接收方五个目标分别位于何处、属于哪个机坪区域、来自哪个 crop、哪些目标仍未验证。第二，图像 latent 与结构关系被压缩为离散 token 后难以

无损恢复。最新的 latent agent communication 工作已经指出，纯文本通信会造成信息损失与额外推理开销，并开始直接交换 hidden state 或压缩 latent [9, 10]。但这些方法并未针对遥感场景的显式空间层次设计通信协议。

另一方面，遥感 Scene Graph 已从静态对象关系扩展到层次化和多尺度表示 [5, 6]；SG2 进一步表明多 Agent 可以对 scene graph 进行按需查询 [7]。但这些工作主要将图视为视觉表示或检索对象，而不是一种贯穿多 Agent 强化学习过程的**共享通信状态**。本文关注的问题因此不是“能否生成遥感 scene graph”，而是：

**能否把遥感空间层次直接变成 Agent 的通信协议，
并让 cooperative RL 学习何时传文本、何时传结构、
何时直接传视觉 latent？**

我们提出 EvoRS-COMM。其核心不是单独增加一个树结构，而是将 Agent communication action 从单一文本消息扩展为多维决策：

$$a_t^{\text{comm}} = (r_t, \ell_t, m_t, p_t), \quad (1)$$

其中 r_t 为接收 Agent， ℓ_t 为 Scene/Region/Group/Object 空间层级， m_t 为 Text/Structure/Latent 通信模态， p_t 为具体 payload。共享状态则由问题、层次树、Agent 历史与通信预算共同组成。随着训练进行，不同 Agent 可以在不同任务中形成不同的责任分工与通信模式，我们将这一现象称为**自然演化协作 (natural-evolving collaboration)**；它指 policy-driven specialization，而非遗传算法意义上的 mutation/crossover。

本文贡献。

- 自然演化遥感多 Agent 框架。**提出以共享遥感空间状态为交互媒介的宏观框架，使 Agent 的合作对象、职责与消息形态能够随任务通过强化学习自适应演化，而非依赖单一 Router 或固定工作流。
- 多 Agent 分层多模态通信。**将遥感图像显式组织为 Scene-Region-Group-Object 四级树，并设计 Text-Structure-Visual Latent 三通道消息，使语义、空间地址与原始视觉证据可以在 Agent 间联合传递。
- 结构化通信 MARL 算法。**在 cooperative MARL/MAGRPO 思路扩展 communication

action space 与优化目标, 同时学习 recipient、hierarchy level、message modality 和 payload, 并加入结构一致性、通信成本与冗余抑制奖励。

4. **系统性实验验证**。设计覆盖 VRSBench、CHOICE、XLRs-Bench 与 GEOBench-VLM 的评测, 包括准确率、跨任务泛化、通信 token、latent bandwidth 与通信效率。由于实验尚未执行, 本文所有结果均为 **TBD**, 不声明未验证的性能优势。

2 相关工作

2.1 遥感层次场景表示

Knyaz 等研究了航拍图的层次 scene graph 与向量化, 将对象关系与层级纳入遥感场景理解 [5]; 后续工作进一步研究多尺度 scene graph generation [6]。这些工作证明了“Scene-Region-Object”结构对于遥感视觉具有合理性, 但主要目标仍是构建或评估 scene graph, 而非将其变成多 Agent 的通信协议。本文不主张层次 scene graph 本身的新颖性, 而是将其改造成可被 Agent 读写、按层级传递、挂接 visual latent 的共享通信状态。

2.2 Scene Graph 与多 Agent 推理

SG2 将 Reasoner 与 Retriever 分离, 使多个 LLM Agent 通过 schema-guided query 从 scene graph 中迭代取数, 避免一次注入完整图 [7]。SaGe 则将 scene graph thinking 用于多模态结构化推理, 并进一步采用 graph-aware post-training [11]。与之不同, 我们关注的是通信本身: 结构树不仅是被查询的数据源, 而是 Agent 消息的显式载体; 同时, 视觉 latent 与自然语言和结构节点一起进入 communication action space。

2.3 多 Agent 强化学习与 latent communication

MAGRPO 将 LLM collaboration 建模为 cooperative MARL, 并通过 multi-agent group-relative policy optimization 联合优化多 Agent 策略 [8]。本文以此类方法为训练基础, 但将通信动作从文本 response 扩展为层次化多模态消息。与此同时, Interlat 已验证 Agent 可以直接交换连续 hidden states, 并报告了显著的推理加速潜力 [9]; MACF 在长视频理解中使用 compact latent tokens 支持多 Agent 协作 [10]。这些结果说明视觉/语言 latent communication 在技术上可行。我们的重点是将 latent 明确绑定到遥感树节点及其 bbox/region, 使连续表示具有可定位、可追溯的空间语义。

3 问题定义

给定遥感图像 I 与问题 q , 系统包含固定基础能力 Agent 集合

$$\mathcal{A}_F = \{A_G, A_L, A_H, A_V\}, \quad (2)$$

分别表示 Global、Local、Hierarchy 与 Verifier Agent; 另设一个没有预定义细粒度职责的残差 Agent A_E 。完整 Agent 池为

$$\mathcal{A} = \mathcal{A}_F \cup \{A_E\}. \quad (3)$$

所有 Agent 共享同一遥感空间树 $\mathcal{T}_t$, 但可拥有独立 LoRA/adaptor 与局部 observation。

系统在每轮 t 维护共享状态

$$S_t = (q, \mathcal{T}_t, H_t, B_t), \quad (4)$$

其中 H_t 为团队交互历史, B_t 为剩余 token、image query、latent bandwidth 等预算。策略输出两类 action: 任务动作 a^{task} 与通信动作 a^{comm} 。目标是在任务正确率与通信/视觉成本之间取得最优权衡。

4 方法

4.1 总体框架: 自然演化协作

我们将“自然演化”定义为从固定初始 Agent 能力出发, 在训练中由 policy 逐渐形成任务依赖的通信拓扑与责任分配。系统不要求所有 Agent 每题都参与, 也不预先固定“计数专家”、“机场专家”等细粒度角色。基础专家只提供少量遥感先验能力, 而 A_E 用于吸收固定角色未覆盖的残差行为。

4.2 四级遥感共享状态

我们使用四级树表示空间层次:

$$\mathcal{T}_t : \text{Scene} \rightarrow \text{Region} \rightarrow \text{Group} \rightarrow \text{Object}. \quad (5)$$

每个节点 v_i 定义为

$$v_i = (id_i, \ell_i, s_i, b_i, c_i, u_i, z_i, p_i), \quad (6)$$

其中 ℓ_i 为层级, s_i 为语义标签, b_i 为 bbox/polygon, c_i 为 confidence, u_i 为 uncertainty, z_i 为可选 visual latent, p_i 为 evidence provenance。一个机场场景可表示为

$$\text{Airport} \rightarrow \text{Apron} \rightarrow \text{AircraftGroup} \rightarrow \text{Aircraft}_k.$$

与自然语言相比, 该状态显式保留“谁属于谁”以及“目标在哪里”, 因此接收 Agent 可以直接使用 b_i 调用 crop/zoom/detector 等视觉工具。




图 1: EvoRS-Comm 总体框架。共享遥感层次状态作为所有 Agent 的显式空间通信骨架。通信不仅包含文本，还可以传递结构化节点/子树以及与节点绑定的视觉 latent。强化学习策略联合决定接收方、空间层级、消息模态和 payload，使协作模式在任务训练中自适应形成。




图 2: 概念性示例：问题驱动的层次细化过程。共享树可以从 Scene 逐步定位到 Region、Group 与 Object，最终把回答所需的对象位置和数量显式交给下游 Agent。图中影像与示意布局用于方法说明，不代表实验结果。

4.3 层次化多模态通信协议

传统 Agent 消息通常只有文本 M^{text} 。我们将消息扩展为

$$M_{i \rightarrow j} = (M^{text}, M^{struct}, M^{latent}), \quad (7)$$

但每次通信无需发送全部三种模态，而是由策略按需选择。

Text channel. 用于自然语言推理、任务意图和高层解释。例如“当前区域可能为机场，但需要验证机坪中的小目标”。

Structured channel. 直接发送一个节点、路径或子树，例如

$$\{\text{Apron}, \text{AircraftGroup}, b_{ROI}, c, u\}.$$

结构消息承担空间地址与语义骨架功能，下游 Agent 不必从文本重新恢复 bbox 与层次关系。

Visual latent channel. 对某个节点对应区域 $I[b_i]$ ，视觉编码器产生

$$z_i = C_\omega(E_{vis}(I[b_i])) \in \mathbb{R}^{K \times d}, \quad (8)$$

其中 C_ω 是可学习压缩器。如果所有 Agent 共享 backbone，则 z_i 可直接复用；若 Agent 异构，则采用投影器 $P_{i \rightarrow j}$ 对齐 latent space。接收 Agent 通过 cross-attention 融合：

$$\tilde{h}_j = h_j + \text{Attn}(h_j, P_{i \rightarrow j} z_i, P_{i \rightarrow j} z_i). \quad (9)$$

因此 Tree 负责“这是什么、在哪里”，latent 负责“它具体长什么样”，text 负责“为什么发送它、下一步推理目的是什么”。

4.4 通信决策空间

在每个 step，通信策略不只选择 next agent，而是选择

$$a_t^{comm} = (r_t, \ell_t, m_t, p_t), \quad (10)$$

其中

$$\begin{aligned} r_t &\in \mathcal{A}, \\ \ell_t &\in \{\text{scene}, \text{region}, \text{group}, \text{object}\}, \\ m_t &\in \{\text{text}, \text{struct}, \text{latent}, \text{hybrid}\}, \\ p_t &\subseteq \mathcal{T}_t. \end{aligned}$$

“hybrid” 可以是 Text+Struct、Struct+Latent 或三者联合。该设计使通信选择本身成为可优化 action：简单高层任务可只传短文本或场景节点；小目标复核可传 Object node + latent；复杂空间关系则传子树。

4.5 结构化通信多智能体强化学习

MAGRPO 已证明可以用 group-relative objective 优化 LLM multi-agent collaboration [8]。我们在此基础上将每个 Agent 的 policy 拆为 task policy 与 communication policy：

$$\pi_i(a_t|o_i, S_t) = \pi_i^{\text{task}}(a_t^{\text{task}}|\cdot) \pi_i^{\text{comm}}(a_t^{\text{comm}}|\cdot). \quad (11)$$

团队奖励设计为

$$R = R_{\text{task}} + \lambda_s R_{\text{struct}} + \lambda_e R_{\text{evid}} - \lambda_c C_{\text{comm}} - \lambda_r C_{\text{red}}. \quad (12)$$

其中 R_{task} 为最终答案奖励； R_{struct} 衡量树结构一致性； R_{evid} 鼓励消息可追溯到视觉证据； C_{comm} 为通信成本； C_{red} 惩罚重复消息。

通信成本按不同模态分别计量：

$$C_{\text{comm}} = \alpha N_{\text{text}} + \beta N_{\text{node}} + \gamma N_{\text{latent}}, \quad (13)$$

使策略在“信息充分”与“带宽开销”之间学习折中。

为避免所有 Agent 重复传递相同结论，我们定义消息新颖性辅助奖励：

$$r^{\text{novel}}(m_t) = 1 - \max_{m \in H_t} \text{sim}(m_t, m), \quad (14)$$

并将其与 evidence gain 结合得到局部 communication reward

$$r_t^{\text{comm}} = \eta_1 \Delta E_t + \eta_2 r^{\text{novel}}(m_t) - \eta_3 \text{cost}(m_t). \quad (15)$$

在 group-relative advantage $\hat{A}^{\text{team}}$ 的基础上，通信分支使用

$$\hat{A}_t^{\text{comm}} = \hat{A}^{\text{team}} + \rho \text{norm}(r_t^{\text{comm}}), \quad (16)$$

从而让“答对但通信极其冗余”与“答对且通信有效”的轨迹获得不同 credit。

最终优化目标采用两套 clipping：

$$\mathcal{L}_{\text{HM-MAGRPO}} = \mathbb{E} \left[\min(r_t^{\text{task}} \hat{A}^{\text{team}}, \text{clip}(r_t^{\text{task}}, 1 \pm \epsilon_t) \hat{A}^{\text{team}}) + \kappa \min(r_t^{\text{comm}} \hat{A}_t^{\text{comm}}, \text{clip}(r_t^{\text{comm}}, 1 \pm \epsilon_c) \hat{A}_t^{\text{comm}}) \right] \quad (17)$$

其中 r_t^{task} 和 r_t^{comm} 分别为新旧策略概率比。式 (17) 是本文相对 generic MAGRPO 的核心算法改动：通信不再被隐含在文本 generation 中，而是作为独立、结构化、可计成本的策略分支进行优化。

Algorithm 1 HM-MAGRPO 训练流程（简化）

Require: dataset $\mathcal{D}$, agent pool $\mathcal{A}$, initial policies π

- 1: **for** each training batch (I, q, y) **do**
- 2: 初始化共享树 $\mathcal{T}_0$ 与预算 B_0
- 3: **for** $t = 0, \dots, T - 1$ **do**
- 4: 各 active Agent 读取 $S_t = (q, \mathcal{T}_t, H_t, B_t)$
- 5: 采样 task action 与 $a_t^{\text{comm}} = (r, \ell, m, p)$
- 6: 发送 Text/Structure/Latent 消息并更新 $\mathcal{T}_{t+1}$
- 7: **if** stop or answer **then**
- 8: **break**
- 9: **end if**
- 10: **end for**
- 11: 计算 $R_{\text{task}}, R_{\text{struct}}, R_{\text{evid}}, C_{\text{comm}}, C_{\text{red}}$
- 12: 对同一问题的 group trajectories 计算 $\hat{A}^{\text{team}}$
- 13: 计算 $\hat{A}^{\text{comm}}$ 并更新 task/communication policies
- 14: **end for**




图 3: 跨层结构一致性示意。高层 Scene/Region 语义与中层 Group、细粒度 Object 证据发生冲突时, 系统触发 revise/refine, 而不是仅在文本层做多数投票。

4.6 跨层结构一致性与证据追溯

树中高层结论必须能被低层节点支持。例如 Aircraft 应属于 AircraftGroup, AircraftGroup 属于 Apron, 而 Apron 属于 Airport。若不同 Agent 写入的结构产生冲突, Verifier 可沿 provenance 定位到具体节点和 ROI, 再调用视觉工具重新验证。

5 实验设计

5.1 Benchmark

我们计划使用四类互补 benchmark: VRSBench 提供 caption、grounding 与 VQA [1]; CHOICE 系统评估遥感 perception/reasoning 能力 [3]; XLRS-Bench 强调平均约 8500×8500 的超高分辨率遥感理解 [2]; GEOBench-VLM 覆盖 scene understanding、counting、localization、fine-grained categorization、segmentation 与 temporal analysis [4]。这些 benchmark 的共同点是图像与问题/指令本身即可使用, 因此本文方法不假设 CRS、GSD 或传感器元数据必然存在。

5.2 实现设置

第一版建议所有 Agent 共享同一个 7B 级 VLM backbone, 不同 Agent 使用独立 prompt 与 LoRA。共享 backbone 使 visual latent 处于同一空间, 避免额外 alignment 成本; 随后再测试异构 Agent + projection。所有 benchmark 使用官方 metric; 最终核心实验至少报告三次随机种子均值与标准差。

5.3 对比方法

建议包含: Single VLM、Single+CoT、Text-only Multi-Agent、Static Structured State、SG2-style graph querying [7]、Generic MAGRPO [8]、Text+Structure、Text+Latent、Full EvoRS-COMM。若 SaGe 可获得可比实现, 则加入 graph-aware reasoning baseline [11]。

5.4 主结果

5.5 关键消融

论文必须至少回答以下问题:

- **分层结构是否有效?** 比较 text-only、flat object list、四级树。
- **latent 是否真的有用?** 在相同通信预算下比较 Text、Struct、Latent 与 Hybrid。
- **RL 算法改动是否必要?** 比较 SFT router、generic MAGRPO 与 HM-MAGRPO。
- **自然演化是否真实发生?** 统计不同 task family 下各 Agent 的调用比例、通信对象、消息模态与空间层级分布。
- **是否只是带宽变大?** 做 matched-bandwidth / matched-token 比较。

5.6 自然演化分析

自然演化不能仅通过最终 accuracy 声明。我们建议报告 communication matrix C_{ij} 、消息模态分布 $P(m|task)$ 、层级分布 $P(\ell|task)$ 以及 residual agent 的 task-wise activation。若训练后出现例如 counting 任务更多采用 Region→Group→Object 的 Struct+Latent 通信, 而 scene classification 更多采用 Scene/Region 的 Text+Struct 通信, 则说明策略确实形成了与任务相匹配的协作分工。

6 讨论

为什么需要结构 + latent, 而不是只用 latent? latent 能保留丰富视觉信息, 但缺乏天然的“地址”与可解释空

间语义; 结构树提供 node id、bbox、parent 与层级, 使 latent 被明确绑定到某个遥感区域。两者组合可以分别承担索引与内容角色。

为什么需要文本? 结构适合空间关系, latent 适合视觉证据, 但复杂推理意图、验证请求与任务解释仍适合语言, 因此本文不是“去文本化”, 而是让 RL 自适应选择三种通信通道。

异构 Agent 的可行性。 第一阶段使用共享 backbone 是最稳定方案; 若采用不同 VLM, 需要解决 latent space alignment。可以训练轻量 projection 或共享 bottleneck tokenizer, 但这应作为后续扩展而非第一版必须条件。

潜在风险。 若树结构由错误 detector/VLM 构造, 其错误可能在团队中传播, 因此 Verifier、uncertainty 与 provenance 机制非常关键。另一个风险是 latent channel 带宽过高, 导致“准确率提升只是因为传更多信息”; 因此 matched-bandwidth 实验是论文必须项。

7 结论

本文提出 EvoRS-COMM 的完整研究设计: 以 Scene-Region-Group-Object 四级遥感共享状态为通信骨架, 使多个 Agent 不再局限于自然语言消息, 而能够按需交换文本、结构化空间节点和 visual latent; 进一步将 recipient、spatial level、message modality 与 payload 显式纳入 cooperative MARL action space, 并设计结构一致性、证据质量、通信成本与冗余奖励。该框架的宏观目标是让 Agent 协作关系和专业责任在任务训练中自然形成。本文当前为方法与实验方案草稿, 所有性能数字均待真实实验验证。

参考文献

- [1] X. Li, J. Ding, and M. Elhoseiny. VRSBench: A Versatile Vision-Language Benchmark Dataset for Remote Sensing Image Understanding. *NeurIPS Datasets and Benchmarks*, 2024.
- [2] F. Wang et al. XLRs-Bench: Could Your Multimodal LLMs Understand Extremely Large Ultra-High-Resolution Remote Sensing Imagery? *CVPR*, 2025, pp. 14325–14336.
- [3] X. An, J. Sun, Z. Gui, and W. He. CHOICE: Benchmarking the Remote Sensing Capabilities of Large Vision-Language Models. *NeurIPS Datasets and Benchmarks*, 2025.

表 1: 主结果模板。所有数值必须由真实实验填写。Comm. Cost 建议同时报告 text tokens、结构节点数与 latent bytes。

Method	VRSBench	CHOICE	XLRS-Bench	GEOBench-VLM	Avg. Score	Comm. Cost
Single VLM	TBD	TBD	TBD	TBD	TBD	TBD
Text-only MAS	TBD	TBD	TBD	TBD	TBD	TBD
Static Tree + MAS	TBD	TBD	TBD	TBD	TBD	TBD
Generic MAGRPO	TBD	TBD	TBD	TBD	TBD	TBD
Text + Structure	TBD	TBD	TBD	TBD	TBD	TBD
Text + Latent	TBD	TBD	TBD	TBD	TBD	TBD
EvoRS-Comm	TBD	TBD	TBD	TBD	TBD	TBD

表 2: 通信模态消融模板。

Message	Score	Tokens	Latent Bytes
Text only	TBD	TBD	0
Struct only	TBD	TBD	0
Latent only	TBD	0	TBD
Text+Struct	TBD	TBD	0
Struct+Latent	TBD	TBD	TBD
Full Hybrid	TBD	TBD	TBD

- [4] M. Danish et al. GEOBench-VLM: Benchmarking Vision-Language Models for Geospatial Tasks. *ICCV*, 2025, pp. 7132–7142.
- [5] V. A. Knyaz, V. V. Kniaz, S. Y. Zheltov, A. V. Emelyanov, and E. R. Smirnov. Hierarchical Scene Graph Generation and Vectorization of Aerial Images. *ISPRS Archives*, 2025, pp. 161–167.
- [6] V. A. Knyaz, V. V. Kniaz, A. V. Emelyanov, S. Y. Zheltov, and V. S. Aleksandrov. Multi-scale Scene

Graph Generation for Remote Sensing Imagery. *ISPRS Archives*, 2026, pp. 215–220.

- [7] Y. Chen et al. Schema-Guided Scene-Graph Reasoning Based on Multi-Agent Large Language Model System. *AAAI*, 2026, pp. 30332–30340.
- [8] S. Liu, Z. Liang, X. Lyu, and C. Amato. LLM Collaboration with Multi-Agent Reinforcement Learning. *AAAI*, 2026, pp. 32150–32158.
- [9] Z. Du et al. Enabling Agents to Communicate Entirely in Latent Space. *ACL*, 2026, pp. 27106–27129.
- [10] K. Chen, J. Wang, J. Zhang, M. Li, Y. Lu, and H. Fan. Scaling Video Understanding via Compact Latent Multi-Agent Collaboration. arXiv:2605.00444, 2026.
- [11] Z. Yang, Y. Wu, N. Zhang, Y. Meng, K. Yan, and S. Ding. Scene Graph Thinking: Reinforcing Structured Visual Reasoning for Multimodal Large Language Models. *ICML*, 2026.